Geração Sintética Guiada por Herança Ativa: Extensão Multi-domínio (COVID19.BR e FACTCK.BR)

Eduardo Alexandre de Amorim[1], Cleber Zanchettin[1]
[1]Centro de Informática, Universidade Federal de Pernambuco, Recife, PE, Brasil
{eaa5, cz}@cin.ufpe.br

TABLE I
CARACTERÍSTICAS DOS QUATRO DOMÍNIOS DO ESTUDO.

Domínio	Gênero	Texto	Prior (fake:true)	Split
Fake.br	notícia	pré-processado	balanceado	aleatório
FakeWhatsApp.Br	WhatsApp	raw	minoritário	temporal
COVID19.BR	WhatsApp	raw	minoritário (≈1:2,5)	temporal
FACTCK.BR	claims	raw	majoritário	aleatório

***Abstract*—Esta extensão replica o estudo controlado de curadoria da revisão 21/out em dois novos domínios do português: COVID19.BR (mensagens de WhatsApp sobre a pandemia, split temporal) e FACTCK.BR (claims verificados por agências de checagem, split aleatório estratificado). Dados os mesmos candidatos zero-shot, quatro regras de herança são comparadas—herdar tudo (*All*), uma amostra aleatória (*Random*-k), o score de erro/incerteza/diversidade (*Score*-k) e o gate invertido (*Easy*-k)—em três cenários de escassez por domínio (full, 10%, 5%). Todos os braços usam ponderação de classes, limiar ajustado na validação e treino final do zero. Os resultados (três seeds, exploratório) são reportados com F1, recall, PR-AUC e custo; nenhum resultado histórico foi sobrescrito.**

***Index Terms*—data-centric AI, synthetic data, misinformation, controlled study, Portuguese NLP, COVID19.BR, FACTCK.BR**

I. INTRODUÇÃO

A revisão 21/out isolou três efeitos confundidos na versão anterior do *ActiveInheritance*: o score de seleção, o volume gerado e a política de treino (limiar fixo 0,5 sem ponderação). O achado central foi que, dados os mesmos candidatos, o score **não** domina a seleção aleatória, e que boa parte do colapso de recall sob escassez era efeito do limiar e do desbalanceamento. Aquela análise, porém, usou um único domínio novo (FakeWhatsApp.Br). Aqui estendemos o mesmo protocolo a dois domínios adicionais para verificar se a conclusão se mantém fora de WhatsApp eleitoral.

II. DATASETS

Os quatro domínios do estudo diferem em gênero, pré-processamento, prior de classe e tipo de split (Tabela I). Os dois primeiros vêm da revisão 21/out; os dois últimos são as contribuições desta extensão.

A. COVID19.BR

Mensagens reais de grupos públicos brasileiros de WhatsApp durante a pandemia de COVID-19 (março–junho/2020), rotuladas manualmente como misinformation. Vem da mesma família do FakeWhatsApp.Br (mesmo grupo de pesquisa e mesmo esquema `text/misinformation`), o que garante texto *raw* nos dois lados—sem o descompasso real-pré-processado vs. sintético que limitava o Fake.br. O split é temporal (treino=março–abril; validação=08–09/junho; teste=10–12/junho): o teste mede generalização para um período posterior da pandemia, e não apenas para uma subamostra aleatória. A classe `fake` é naturalmente minoritária (≈1:2,5), exatamente o regime de escassez para o qual o método foi desenhado.

B. FACTCK.BR

Claims verificados por agências brasileiras de checagem (Aos Fatos, Lupa, Truco), coletados via schema ClaimReview entre 2016 e 2019. É um gênero distinto: alegações curtas, não mensagens nem artigos completos. O texto usado é o `claimReviewed` (a própria alegação); o `reviewBody` foi excluído porque declara o veredito e vazaria o rótulo. A binarização é estrita (falso/falsa → fake; verdadeiro/verdadeira → true; demais rótulos descartados). O split é aleatório estratificado 70/15/15 (seed 42): o temporal foi evitado porque os claims `true` se concentram em 2016–2018, deixando 2019 sem classe negativa. Diferentemente dos demais, é *fake-majoritário* (agências checam majoritariamente claims falsos), servindo como teste de robustez a um prior oposto.

III. PROTOCOLO

Idêntico ao da revisão 21/out: uma geração zero-shot por cenário/seed (`candidates.json`) e quatro replays offline sobre os *mesmos* lotes. `deepseek-chat`, prompt v4 (WhatsApp anti-template) para COVID19.BR e prompt v2 (notícia) para FACTCK.BR, teto de 100 mil tokens por geração, T=5, batch 64, top-k=16. Learner BERTimbau, 3 épocas por fit, ponderação de classes e limiar na validação; treino final do zero em $D_0 \cup H$. Seeds 42–44 (n=3, exploratório).

IV. RESULTADOS

Tabela II reporta F1 (média ± desvio) por domínio, cenário e braço. Tabela III traz recall, PR-AUC, limiar e número de sintéticos herdados.

TABLE II
F1 (TESTE) POR DOMÍNIO, CENÁRIO E BRAÇO. n=3 SEEDS.

Domínio	Cen.	All	Random-k	Score-k
COVID19.BR	full	0.824 ± 0.024	0.836 ± 0.013	0.857 ± 0.003
COVID19.BR	10%	0.789 ± 0.017	0.732 ± 0.049	0.805 ± 0.018
COVID19.BR	5%	0.468 ± 0.029	0.704 ± 0.039	0.668 ± 0.062
FACTCK.BR	full	0.929 ± 0.004	0.931 ± 0.006	0.932 ± 0.010
FACTCK.BR	10%	0.816 ± 0.044	0.931 ± 0.011	0.934 ± 0.007
FACTCK.BR	5%	0.765 ± 0.076	0.928 ± 0.010	0.935 ± 0.006

TABLE III
RECALL, PR-AUC, LIMIAR E SINTÉTICOS HERDADOS (MÉDIA).

Domínio	Cen.	Braço	Recall	PR-AUC	n_synth
COVID19.BR	full	all	0.802	0.886	277
COVID19.BR	full	random-k	0.822	0.897	80
COVID19.BR	full	score-k	0.871	0.901	80
COVID19.BR	full	easy-k	0.853	0.907	80
COVID19.BR	10%	all	0.791	0.853	278
COVID19.BR	10%	random-k	0.653	0.848	80
COVID19.BR	10%	score-k	0.789	0.853	80
COVID19.BR	10%	easy-k	0.731	0.861	80
COVID19.BR	5%	all	0.322	0.792	278
COVID19.BR	5%	random-k	0.660	0.818	80
COVID19.BR	5%	score-k	0.591	0.801	80
COVID19.BR	5%	easy-k	0.498	0.806	80
FACTCK.BR	full	all	0.959	0.971	313
FACTCK.BR	full	random-k	0.969	0.968	80
FACTCK.BR	full	score-k	0.966	0.965	80
FACTCK.BR	full	easy-k	0.952	0.967	80
FACTCK.BR	10%	all	0.734	0.961	312
FACTCK.BR	10%	random-k	0.978	0.961	80
FACTCK.BR	10%	score-k	0.986	0.961	80
FACTCK.BR	10%	easy-k	0.986	0.963	80
FACTCK.BR	5%	all	0.657	0.952	312
FACTCK.BR	5%	random-k	0.969	0.955	80
FACTCK.BR	5%	score-k	0.988	0.957	80
FACTCK.BR	5%	easy-k	0.978	0.960	80

V. DISCUSSÃO

Os resultados confirmam e refinam a conclusão da revisão 21/out em dois domínios novos, com quatro insights principais.

(i) O score não domina — e o controle aleatório continua sendo a barreira. No COVID19.BR, *Score*-k só vence *Random*-k no cenário full (0,857 vs. 0,836) e por margem pequena; sob escassez, *Random*-k empata ou vence (5%: 0,704 vs. 0,668). No FACTCK.BR os quatro braços ficam praticamente empatados em todos os cenários. Dados os mesmos candidatos, o score de erro/incerteza/diversidade não agrega sobre uma seleção aleatória.

(ii) O efeito real é curadoria de volume, não o score. *All* herda 277–313 sintéticos; os demais herdam ≈80. Em escassez extrema (COVID19.BR 5%), *All* colapsa para F1 0,468 enquanto os braços curados ficam em 0,60–0,70. Herdar *menos* e manter o treino rebalanceado importa mais do que *o quê* se herda.

(iii) A seleção só agrega num regime intermediário de dificuldade — quando o learner inicial já é bom. No FACTCK.BR a tarefa é fácil (*All* já alcança 0,929 no full) e a regra de seleção se torna irrelevante: os quatro braços empatam. No COVID19.BR 5% a tarefa é difícil (*All* colapsa para 0,468) e o score também não ajuda—*Random*-k vence. Só

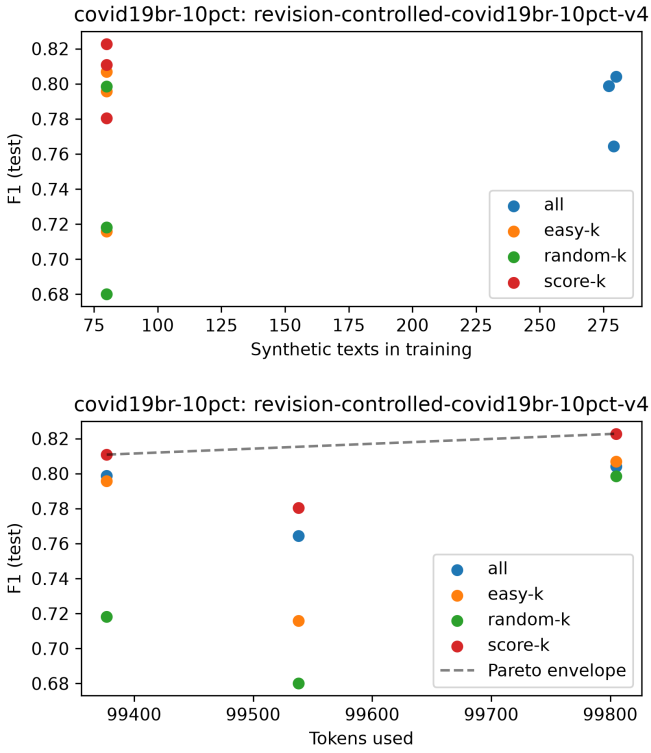


Fig. 1. Pareto F1 × recursos (cenário full).

no COVID19.BR full, dificuldade intermediária (*All*=0,824), o score agrega um pouco (0,857). Isso ecoa o achado do Fake.br e do FakeWhatsApp.Br: a herança guiada pressupõe um learner suficientemente competente; quando ele é fraco, seu próprio sinal de erro/incerteza é ruído e não supera o sorteio.

(iv) Calibração (pesos + limiar) continua fazendo o trabalho pesado. Os limiares escolhidos na validação caem para 0,05–0,11 nos cenários de escassez: sem ponderação de classes e limiar ajustado, o modelo subestima a classe minoritária e o recall colapsa (efeito já documentado na revisão). Boa parte do F1 observado é política de treino, não qualidade intrínseca do sintético.

VI. FIGURAS

Fronteiras Pareto de F1 × tokens e F1 × n_sintéticos para os cenários completos:

Figuras adicionais (todos os cenários):

- `revision-controlled-covid19br-10pct-v4-covid19b`
- `revision-controlled-covid19br-10pct-v4-covid19b`
- `revision-controlled-covid19br-5pct-v4-covid19br`
- `revision-controlled-covid19br-5pct-v4-covid19br`
- `revision-controlled-covid19br-full-v4-covid19br`
- `revision-controlled-covid19br-full-v4-covid19br`
- `revision-controlled-factckbr-10pct-v2-factckbr-`
- `revision-controlled-factckbr-10pct-v2-factckbr-`
- `revision-controlled-factckbr-5pct-v2-factckbr-5`
- `revision-controlled-factckbr-5pct-v2-factckbr-5`
- `revision-controlled-factckbr-full-v2-factckbr-f`

- revision-controlled-factckbr-full-v2-factckbr-full-f1-vs-n_synthetic-20261026T064953Z.png
- revision-controlled-fakewhatsapp-10pct-v4-fakewhatsapp-10pct-f1-vs-n_synthetic-20261023T003
- revision-controlled-fakewhatsapp-10pct-v4-fakewhatsapp-10pct-f1-vs-tokens_used-20261023T003
- revision-controlled-fakewhatsapp-5pct-v4-fakewhatsapp-5pct-f1-vs-n_synthetic-20261023T00353
- revision-controlled-fakewhatsapp-5pct-v4-fakewhatsapp-5pct-f1-vs-tokens_used-20261023T00353
- revision-controlled-fakewhatsapp-full-v4-fakewhatsapp-full-f1-vs-n_synthetic-20261023T00352
- revision-controlled-fakewhatsapp-full-v4-fakewhatsapp-full-f1-vs-tokens_used-20261023T00352

VII Limitações

- FACTCK.BR usa split aleatório (não temporal) e prior invertido (fake majoritária); não comparar diretamente com FakeWhatsApp.Br/COVID19.BR sem ressalvar.
- FACTCK.BR é pequeno ($\approx$1.0k claims após binarização); a classe `true` no teste é escassa ($\approx$18 exemplos).
- COVID19.BR não tem dados em maio/2020; o teste é um futuro curto (junho).
- n=3 seeds; não declarar significância estatística.
- Rótulos sintéticos são assumidos `fake` sem checagem humana; veracidade exige evidência externa.