Geração Sintética Guiada por Herança Ativa para Detecção de Desinformação

Eduardo Alexandre de Amorim[1], Cleber Zanchettin[1]
[1]Centro de Informática, Universidade Federal de Pernambuco, Recife, PE, Brasil
{eaa5, cz}@cin.ufpe.br

***Abstract*—A escassez de exemplos rotulados limita classificadores de desinformação, e a geração sintética indiscriminada pode introduzir redundância, artefatos e ruído. Este trabalho revisa o *ActiveInheritance* como um estudo controlado de curadoria: dados os mesmos candidatos gerados por um modelo de linguagem, o que vale a pena herdar para treinar o classificador downstream? Comparamos quatro regras sobre os mesmos lotes em português—herdar tudo (*All*), uma amostra aleatória (*Random*-k), o score de erro/incerteza/diversidade (*Score*-k) e o gate invertido (*Easy*-k)—em três cenários temporais do Fake-WhatsApp.Br. Também reavaliamos os pools antigos com ponderação de classes e limiar ajustado na validação, além de PR-AUC/ROC-AUC. Resultados (três seeds, exploratório) mostram que o score não domina a seleção aleatória: *Random*-k empata no cenário completo e lidera sob escassez (10% e 5%). A ponderação de classes e o limiar recuperam o recall que antes colapsava (Real 5%: F1 de $0{,}000$ para $0{,}642$). Concluímos que o benefício observado é curadoria de volume e calibração de treino, não o score em si.**

***Index Terms*—data-centric AI, synthetic data, misinformation detection, active learning, controlled study, large language models, Portuguese NLP**

I. Introdução

A detecção automática de desinformação em português é limitada por escassez de exemplos positivos, mudança de domínio e custo de anotação. Modelos de linguagem permitem gerar dados sintéticos, mas volume não garante utilidade: gerações repetem templates, afastam-se da distribuição real ou recebem rótulos presumidos incorretos [5].

A versão anterior deste trabalho propôs o *ActiveInheritance*: herdar ciclicamente os candidatos com maior erro, incerteza e diversidade. Os resultados, porém, misturavam três efeitos—o score, o volume gerado e a sequência de retreinos—e usavam limiar fixo de $0{,}5$ sem ponderação de classes, o que confundia qualidade sintética com política de treino. Esta revisão isola esses fatores. As perguntas de pesquisa são:

RQ1 (qualidade) Dados os mesmos candidatos, selecionar por erro/incerteza/diversidade produz dados mais úteis que uma seleção aleatória?

RQ2 (eficiência) Herdar um subconjunto curado é melhor que usar toda a geração, em função do número de sintéticos e de tokens?

RQ3 (robustez) Quanto do colapso de recall sob escassez é efeito do limiar fixo e do desbalanceamento, e não do gate?

A contribuição é um **estudo controlado de curadoria** em português e split temporal: quatro braços sobre os *mesmos* candidatos zero-shot, com ponderação de classes, limiar ajustado na validação, PR-AUC/ROC-AUC e treino final do zero.

Trabalhos relacionados. O trabalho se insere em *data-centric AI* e em *active learning* [7]. A literatura de geração sintética zero-shot (e.g., ZeroGen e ProGen) gera exemplos para treinar modelos; a *Dataset Cartography* [6] diagnostica a dificuldade de exemplos pela dinâmica de treino. Nosso estudo não propõe novo gerador nem novo score: mede, de forma controlada, *quando* uma regra de seleção ajuda—em português e com split temporal.

II. Método

A. Loop e score

Dado um treino real D_0, um learner f e um pool herdado H, um gerador produz um lote S_t por ciclo. Para cada texto x, o avaliador calcula

$$s(x) = w_e\, e(x) + w_u\, u(x) + w_d\, d(x), \tag{1}$$

onde e é o log-loss presumindo rótulo `fake`, u é a entropia binária normalizada e d é a diversidade (um menos a maior similaridade de cosseno contra H, com MiniLM multilíngue). Configuração: $(w_e, w_u, w_d) = (0{,}4, 0{,}4, 0{,}2)$, $T = 5$, batch 64, top-$k = 16$.

B. Quatro braços sobre os mesmos candidatos

- **All**: herda todos os candidatos de cada lote.
- **Random-**k: herda k candidatos sorteados (controle para o efeito do score).
- **Score-**k: herda o top-k pela Eq. (1).
- **Easy-**k: herda o *bottom-*k pela Eq. (1) (inversão estilo Profile2Gen [1], que remove hard samples).

C. Protocolo corrigido

(i) geração **zero-shot** (sem exemplos herdados) para que os quatro braços compartilhem os mesmos lotes; (ii) **ponderação de classes** em todos os braços, incluindo o treino real; (iii) **limiar ajustado na validação** (não fixo em $0{,}5$) e reporte de PR-AUC/ROC-AUC; (iv) treino final de um BERT **novo** em $D_0 \cup H$; (v) registro de tokens de entrada/saída e custo. O pool antigo guardava apenas herdados; por isso os braços Random/Easy/Score/All desta revisão usam geração nova com candidatos completos salvos.

TABLE I
ESTUDO CONTROLADO: QUATRO BRAÇOS SOBRE OS MESMOS CANDIDATOS (MÉDIA ± DESVIO, 3 SEEDS).

Cenário	Braço	F1	Recall	PR-AUC	Limiar	n_{synth}
Full	All	$0{,}726 \pm 0{,}007$	0,820	0,762	0,25	277
Full	Random-16	$0{,}724 \pm 0{,}013$	0,781	0,772	0,27	80
Full	**Score-16**	$\mathbf{0{,}734 \pm 0{,}003}$	0,818	0,769	0,17	80
Full	Easy-16	$0{,}723 \pm 0{,}004$	0,778	0,766	0,20	80
10%	All	$0{,}416 \pm 0{,}130$	0,308	0,662	0,05	277
10%	**Random-16**	$\mathbf{0{,}561 \pm 0{,}063}$	0,488	0,676	0,05	80
10%	Score-16	$0{,}552 \pm 0{,}045$	0,471	0,660	0,05	80
10%	Easy-16	$0{,}519 \pm 0{,}083$	0,439	0,672	0,05	80
5%	All	$0{,}480 \pm 0{,}161$	0,416	0,636	0,05	276
5%	**Random-16**	$\mathbf{0{,}607 \pm 0{,}059}$	0,628	0,641	0,05	80
5%	Score-16	$0{,}532 \pm 0{,}107$	0,493	0,638	0,05	80
5%	Easy-16	$0{,}576 \pm 0{,}034$	0,523	0,648	0,05	80

III. CONFIGURAÇÃO EXPERIMENTAL

Usamos o FakeWhatsApp.Br [3] (6.926 mensagens únicas, rótulo manual), texto raw e split temporal: julho–agosto (treino), setembro (validação) e outubro (teste). Cenários: *full* (474 fake/683 true), *10%* (47/683) e *5%* (23/683). Learner BERTimbau [4], três épocas por fit, batch 16, comprimento 256; gerador `deepseek-chat`, prompt v4 (anti-template), teto de 100 mil tokens por geração. Seeds 42–44. Com três seeds, o Wilcoxon bilateral não atinge $p < 0{,}05$; os resultados são exploratórios.

A Fase B re-treina BERTimbau do zero nos pools sintéticos *já salvos* (zero API) com ponderação e limiar, comparando ao protocolo antigo (limiar $0{,}5$, sem pesos).

Seeds. Para o WhatsApp, treino/validação/teste são fixos; a seed muda a inicialização do BERT e a ordem de treino, além da estocasticidade da geração LLM (que não é determinística no servidor). No Fake.br antigo, a seed também dividia treino/validação; na revisão, criamos uma validação fixa (80/20 estratificado, seed 42) para não escolher método olhando o teste.

Custo. A geração é zero-shot e compartilhada pelos quatro braços: 9 gerações completas somaram 895.512 tokens (321.435 de entrada e 574.077 de saída), custo estimado de US$0,72 pelos preços do código (aproximados; conferir fatura do provedor). O protocolo antigo do AI consumia ≈2 mil tokens por candidato porque o prompt carregava exemplos herdados; o Static gerava com prompt vazio (≈650 tokens/candidato).

O Fake.br não é reportado no estudo controlado: seu pré-processamento original não está disponível no repositório, então a normalização aproximada do sintético não deve ser tratada como equivalência exata. A validação fixa do Fake.br foi criada (`scripts/make_fakebr_val.py`), mas os resultados históricos do Fake.br seguem com a ressalva de pré-processamento.

IV. RESULTADOS

A Tabela I responde às RQs. **RQ1**: o score não domina a seleção aleatória—empata no full e *perde* para o Random-16 em 10% e 5%. **RQ2**: os braços com $k = 16$ (80 textos) superam o All (277) na maioria dos cenários, indicando que o ganho é curadoria de volume, não de geração extra. **RQ3** é tratada na Tabela II.

TABLE II
REPLAY DOS POOLS ANTIGOS COM PONDERAÇÃO E LIMIAR (VS. PROTOCOLO ANTIGO).

Cenário	Braço	F1 novo	Recall	PR-AUC	Limiar	F1 antigo
Full	Real	$0{,}723 \pm 0{,}002$	0,767	0,768	0,27	0,676
Full	Static	$0{,}728 \pm 0{,}003$	0,840	0,758	0,32	0,715
Full	AI	$0{,}728 \pm 0{,}002$	0,827	0,764	0,37	0,708
10%	Real	$0{,}621 \pm 0{,}031$	0,580	0,705	0,05	0,075
10%	Static	$0{,}357 \pm 0{,}225$	0,291	0,682	0,05	0,229
10%	AI	$0{,}467 \pm 0{,}239$	0,465	0,665	0,05	0,179
5%	Real	$0{,}642 \pm 0{,}043$	0,722	0,665	0,06	0,000
5%	Static	$0{,}431 \pm 0{,}207$	0,379	0,625	0,05	0,099
5%	AI	$0{,}464 \pm 0{,}082$	0,373	0,637	0,05	0,055

A Tabela II mostra que boa parte do "colapso de recall" era limiar fixo e desbalanceamento: o Real 10% sobe de $0{,}075$ para $0{,}621$ e o Real 5% de $0{,}000$ para $0{,}642$ apenas corrigindo o protocolo de avaliação/treino (zero tokens). Sob escassez, Static/AI ficam abaixo do Real ponderado, porque a seleção depende de um learner inicial competente.

Revisita ao Fake.br (histórico). O resultado mais favorável à curadoria estava escondido na comparação de mesmo volume: no Fake.br 10% (protocolo antigo), o Static com 79 sintéticos obteve F1 $0{,}852 \pm 0{,}034$ (recall 0,749, 52k tokens) e o AI com ≈80 herdados obteve $0{,}924 \pm 0{,}007$ (recall 0,863, 645k tokens)—$+0{,}072$ com o mesmo número de sintéticos no treino, mas com gerador/prompt diferentes (few-shot herdado no AI) e $6{,}3\times$ mais tokens. Esse contraste sustenta a tese de curadoria melhor que o $+0{,}008$ contra o Static 158, porém não isola o score.

Atalhos de template. No protocolo antigo (v3), 91–93% das gerações Static começavam por "URGENTE" contra ≈1% no real; o AI filtrava para 29–36%. A Wasserstein, porém, era levemente pior no AI (0,176 vs. 0,162 no full), sinal de que o gate remove o template mais fácil de detectar mas empurra o pool para fora da distribuição real. O prompt v4 desta revisão evita "URGENTE", mas ainda vaza "fictícia"/"inventada" e aberturas em caixa alta.

Um classificador logístico (TF-IDF unigramas+bigramas, split aleatório) separa texto real de sintético com AUC $\approx 1{,}0$ em todos os cenários e braços. Isso quantifica o atalho estilístico, mas *não* mede veracidade nem generalização temporal; o prompt v4 ainda vaza marcadores como "fictícia" e "inventada", que podem inflar a separabilidade.

V. DISCUSSÃO

A versão anterior atribuía ganho ao score, mas não havia o controle aleatório. Com os mesmos candidatos, o score não supera o sorteio: o efeito relevante é **herdar pouco** (80 em vez de 277) e **calibrar o treino** (ponderação e limiar). O gate por erro/incerteza/diversidade permanece útil como filtro de redundância, mas não é a fonte do ganho de desempenho.

O *Easy*-k (inversão do Profile2Gen) não supera consistentemente, então a hipótese de "herdar os difíceis" não foi confirmada neste domínio. A seleção por faixa de dificul-

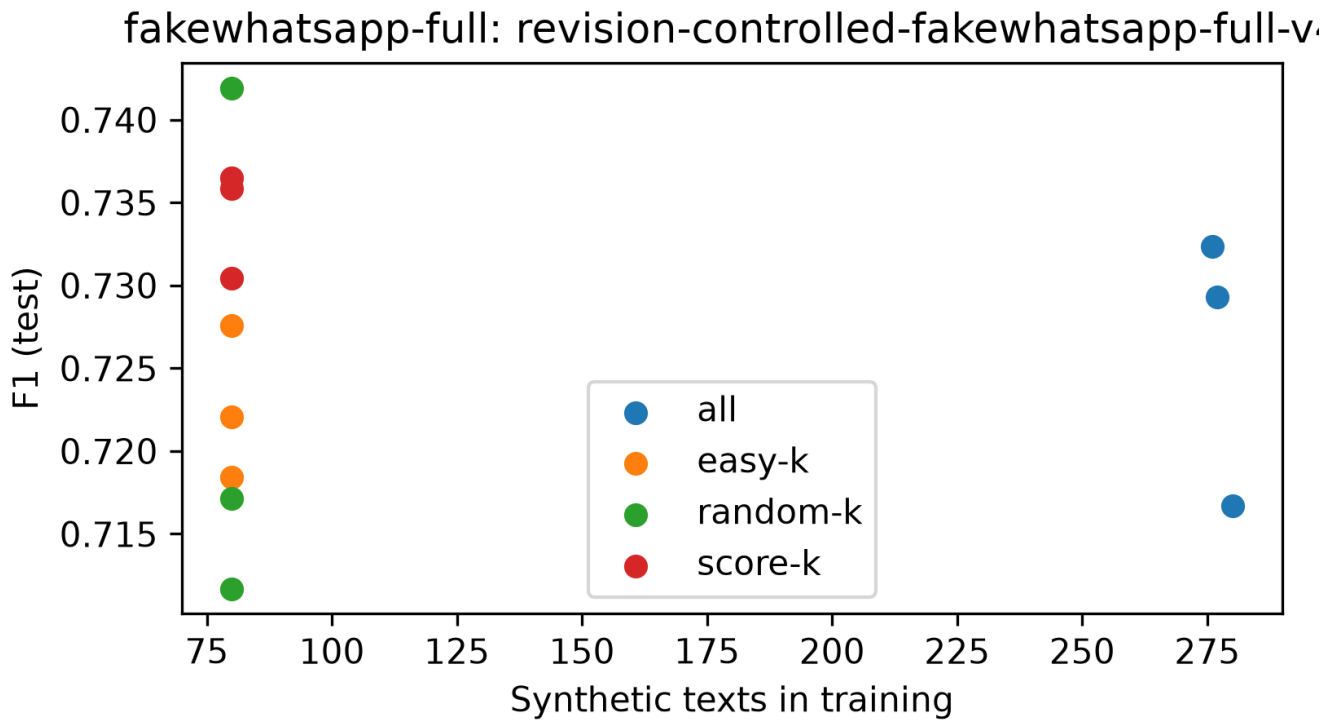


Fig. 1. F1 × número de sintéticos no treino (full). A curadoria de 80 textos atinge ou supera o uso de todos os 277 candidatos.

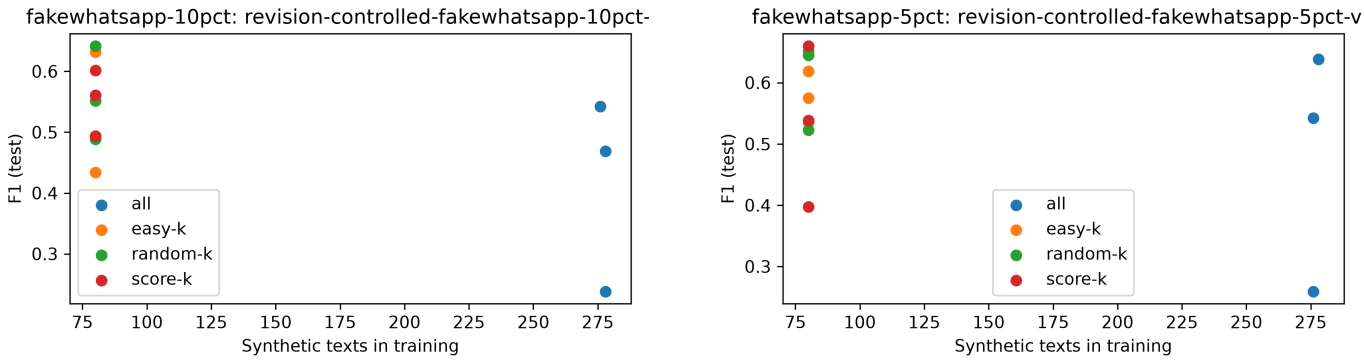


Fig. 2. F1 × número de sintéticos sob escassez (10% à esquerda, 5% à direita). Random-16 supera Score-16 e All em ambos.

dade intermediária fica como ablação futura, condicionada a checagem humana de rótulo.

VI. Limitações e Próximos Passos

Três seeds (exploratório); rótulos sintéticos presumidos sem checagem factual humana; Fake.br ausente (pré-processamento exato indisponível); marcadores vazados no prompt v4. Próximos passos: (i) 10 seeds confirmatórias antes de olhar o holdout final; (ii) validação humana dos sintéticos; (iii) corpus raw ou pipeline exato do Fake.br; (iv) ablação de faixa de dificuldade; (v) trabalhos relacionados posicionando o estudo em ZeroGen/ProGen, active learning e dataset cartography [6], [7].

VII. Conclusão

O ActiveInheritance, sob protocolo controlado, funciona como **curadoria de volume e calibração**, não como superioridade do score. Dados os mesmos candidatos, selecionar por erro/incerteza/diversidade não supera a seleção aleatória; e o colapso de recall sob escassez era majoritariamente limiar fixo e desbalanceamento. Esta revisão delimita onde a herança ativa ajuda—e onde o ganho não é atribuível à função de seleção.

References

[1] M. D. de Souza and C. Zanchettin, "Breaking the Barrier of Hard Samples: A Data-Centric Approach to Synthetic Data for Medical Tasks," in *Proc. ICML*, 2025.

[2] R. Monteiro, R. Santos, T. Pardo, T. de Almeida, E. Ruiz, and O. Vale, "Contributions to the Study of Fake News in Portuguese: New Corpus and Automatic Detection Results," in *Proc. PROPOR*, 2018.
[3] L. Cabral et al., "FakeWhatsApp.Br: NLP and Machine Learning Techniques for Misinformation Detection in Brazilian Portuguese WhatsApp Messages," in *Proc. ICEIS*, 2021.
[4] F. Souza, R. Nogueira, and R. Lotufo, "BERTimbau: Pretrained BERT Models for Brazilian Portuguese," in *Proc. BRACIS*, 2020.
[5] I. Shumailov et al., "AI Models Collapse When Trained on Recursively Generated Data," *Nature*, vol. 631, 2024.
[6] S. Swayamdipta, R. Schwartz, N. Lourie, Y. Wang, H. Hajishirzi, N. A. Smith, and Y. Choi, "Dataset Cartography: Mapping and Diagnosing Datasets with Training Dynamics," in *Proc. EMNLP*, 2020.
[7] B. Settles, *Active Learning*, ser. Synthesis Lectures on Artificial Intelligence and Machine Learning. Morgan & Claypool, 2012.