Geração Sintética Guiada por Herança Ativa para Detecção de Textos Fraudulentos

Eduardo Alexandre de Amorim[1], Cleber Zanchettin[1]
[1]Centro de Informática, Universidade Federal de Pernambuco, Recife, PE, Brazil
{eaa5, cz}@cin.ufpe.br

***Abstract*—A escassez e o desbalanceamento de dados reais em cibersegurança dificultam o treinamento de classificadores robustos contra textos fraudulentos. A geração de dados sintéticos via modelos de linguagem é uma alternativa, mas processos gerativos estáticos podem causar colapso de distribuição e baixa cobertura de casos raros. Este trabalho investiga a *Herança Ativa*: um loop gerativo cíclico em que um avaliador adversarial prioriza amostras sintéticas com base no erro, na incerteza e na diversidade de um classificador. Em experimentos com o corpus Fake.br em cenário de escassez (10% da classe fraudulenta), o método alcançou F1 de 0.924, superior à geração estática (0.916) e ao treino sem dados sintéticos (0.887), com a menor variância entre sementes (desvio padrão 0.007). Entretanto, a hipótese de eficiência computacional não foi confirmada: o método consome mais tokens que a geração estática para atingir o mesmo F1.**

***Index Terms*—synthetic data generation, large language models, fake news detection, data-centric AI, active inheritance**

Reproducibility

Código do projeto: https://github.com/Edu-p/active-inheritance-fraud. Baseline: https://github.com/szanara/profile2gen. Dados: Fake.br-Corpus (7,200 notícias, 3,600 falsas e 3,600 verdadeiras). Cenário de escassez: treino com 10% da classe falsa (288 falsas, 2,880 verdadeiras) e holdout balanceado intacto (720/720). Classificador: BERTimbau (`neuralmind/bert-base-portuguese-cased`). Embeddings: MiniLM multilíngue (`paraphrase-multilingual-MiniLM-L12-v2`). Gerador: `deepseek-chat`. Sementes: 42, 43, 44. GPU: NVIDIA RTX 4060 (8 GB).

I. Introdução

A detecção de textos fraudulentos (notícias falsas, phishing, anúncios enganosos) sofre com a escassez e o desbalanceamento de dados reais [1]. Embora a geração de dados sintéticos via modelos de linguagem seja uma alternativa, processos estáticos frequentemente resultam em colapso do modelo e baixa cobertura de casos raros [6]. Este trabalho adapta o framework *Profile2Gen* [1] — originalmente proposto para dados tabulares de regressão — ao domínio textual de classificação, introduzindo um *avaliador adversarial* no loop gerativo. A diferença conceitual central é uma inversão do baseline: enquanto o Profile2Gen *remove* amostras difíceis no pós-processamento, a Herança Ativa *herda* as amostras difíceis/incertas como "treino deliberado" para o classificador.

© 2026 IEEE. Personal use of this material is permitted. Permission from IEEE must be obtained for all other uses, in any current or future media, including reprinting/republishing this material for advertising or promotional purposes, creating new collective works, for resale or redistribution to servers or lists, or reuse of any copyrighted component of this work in other works.

Fig. 1. Herança Ativa (loop cíclico).

1: Treina learner f em Data 0 (treino escasso)
2: Pool herdado $H \leftarrow \emptyset$
3: **for** $t = 0$ **to** $T - 1$ **do**
4: Gera lote S_t via LLM condicionado em H
5: $\forall x \in S_t$: $score(x) = w_1 err(x) + w_2 unc(x) + w_3 div(x)$
6: $H_t \leftarrow$ top-$k(S_t, score)$
7: $H \leftarrow H \cup H_t$
8: Retreina f em Data 0 $\cup H$
9: **end for**
10: **return** avalia f no holdout de teste

As contribuições são: (i) um loop gerativo cíclico guiado por erro, incerteza e diversidade; (ii) uma avaliação no corpus Fake.br em cenário de escassez; e (iii) uma análise das dimensões de robustez, diversidade e custo computacional.

II. Solução Proposta

O pipeline (Algoritmo 1) opera em ciclos. A cada ciclo t, o LLM gera um lote S_t condicionado ao pool herdado H (few-shot). Um classificador (*learner*) produz $p(y|x)$ e o erro por amostra; um codificador produz embeddings para a diversidade. O avaliador adversarial atribui a cada amostra um escore multiobjetivo:

$$score(x) = w_1 \cdot err(x) + w_2 \cdot unc(x) + w_3 \cdot div(x), \quad (1)$$

onde err é o log-loss do learner, unc é a entropia normalizada de $p(y|x)$, e div é a distância de cosseno máxima ao pool herdado (diversidade). As k amostras de maior escore (fronteira de decisão) são herdadas para o próximo ciclo e injetadas no treino. Usamos $w_1{=}w_2{=}0.4$ e $w_3{=}0.2$.

III. Experimentos

A. Configuração

Três braços são comparados: **Real** (treina apenas no treino escasso), **Static** (geração estática: o LLM gera N amostras com prompt genérico e todas são adicionadas) e **ActiveInheritance** (método proposto, $T{=}5$, lote 64, top-k 16). Métricas: F1, precisão e revocação no holdout balanceado; diversidade (similaridade de cosseno média do pool); fidelidade (distância de Wasserstein entre embeddings reais e sintéticos, projetados nas top-3 componentes PCA dos reais); e custo (tokens acumulados). O Static varia o orçamento: $N \in \{32, 79, 158\}$.

TABLE I
F1 NO TESTE E CUSTO POR BRAÇO (MÉDIA ± DESVIO ENTRE 3 SEMENTES).

Braço	F1	tokens/run
Real	0.887 ± 0.026	0
Static (N=32)	0.789 ± 0.113	∼20k
Static (N=79)	0.852 ± 0.034	∼53k
Static (N=158)	0.916 ± 0.013	∼103k
ActiveInheritance	$\mathbf{0.924 \pm 0.007}$	∼645k
Ablação pesos (E4)	0.930	∼651k
Ablação top-k=8 (E5)	0.919	∼657k

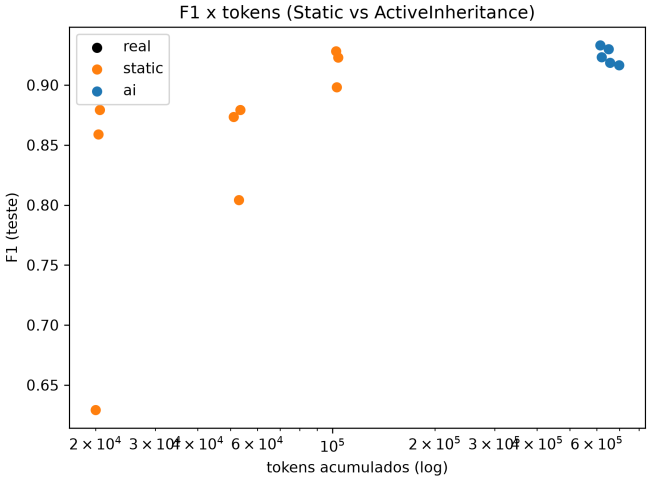


Fig. 2. F1 × tokens acumulados (log). AI atinge o topo com mais tokens.

B. Resultados

A Tabela I resume o desempenho (média ± desvio entre sementes).

IV. Figuras e Análise

A Figura 2 compara o F1 em função dos tokens acumulados: o método proposto atinge o maior F1, mas à custa de um orçamento de tokens cerca de 6× maior que o melhor Static. A Figura 3 mostra o F1 por ciclo, evidenciando o ganho incremental do pool herdado. A Figura 4 mostra que a fidelidade (Wasserstein) é semelhante entre os métodos. A Figura 5 mostra que a diversidade do pool cai ao longo dos ciclos — o canal de diversidade não impede o top-k de concentrar amostras similares. A Figura 6 evidencia a menor variância entre sementes do método proposto. A Figura 7 decompõe o escore por ciclo.

V. Discussões

Três achados principais emergem. **(1) Consistência:** o método proposto tem o menor desvio entre sementes (0.007), enquanto o Static com N=32 colapsa em uma semente (F1 0.63) — evidência de que a geração estática em baixo volume pode envenenar a distribuição, como alertado por [1]. **(2) F1:** o método atinge 0.924, acima do melhor Static (0.916) e do Real (0.887), embora a diferença não seja estatisticamente

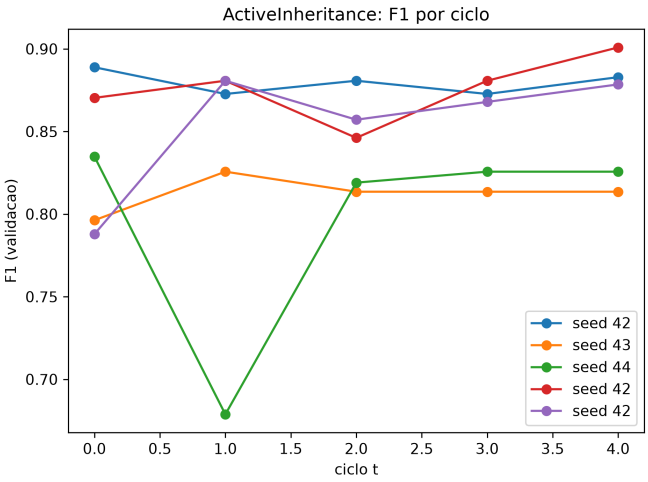


Fig. 3. F1 por ciclo do ActiveInheritance.

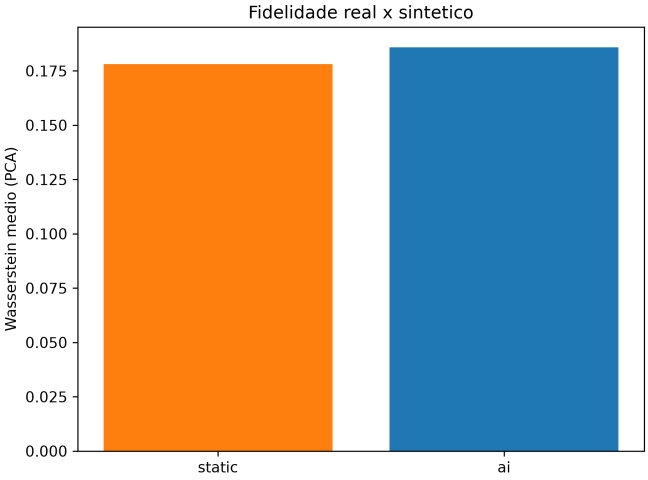


Fig. 4. Wasserstein real × sintético (fidelidade).

significativa com n=3 sementes (Wilcoxon p=0.25; Kruskal-Wallis p=0.15). **(3) Eficiência:** a hipótese de custo não foi confirmada — o método gera 320 amostras por run (∼645k tokens) contra 158 do melhor Static (∼103k tokens) para F1 comparável. Para testar a tese de eficiência, seria necessário reduzir o lote do método (ex.: lote 32) para igualar o orçamento de tokens do Static.

VI. Conclusão

A Herança Ativa produziu o classificador mais consistente e com o maior F1 no cenário de escassez, mas não demonstrou vantagem de eficiência de tokens na configuração atual. Como trabalho futuro, planeja-se: (i) igualar os orçamentos de tokens entre os braços; (ii) calibrar o canal de diversidade para evitar a concentração do pool; e (iii) avaliar o protocolo TSTR (treinar apenas no sintético).

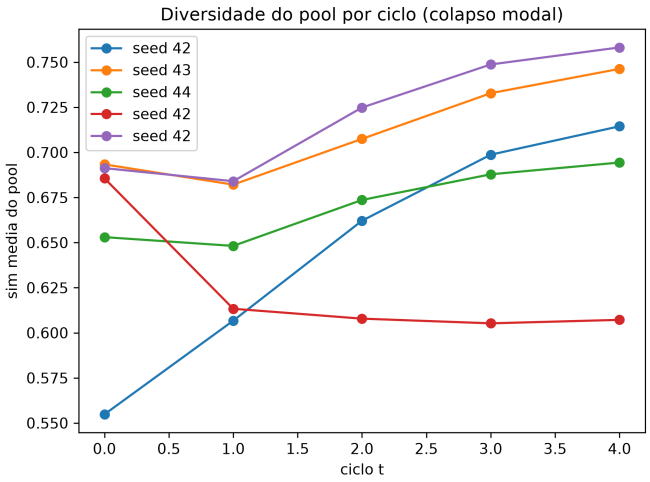


Fig. 5. Diversidade do pool (similaridade média) por ciclo.

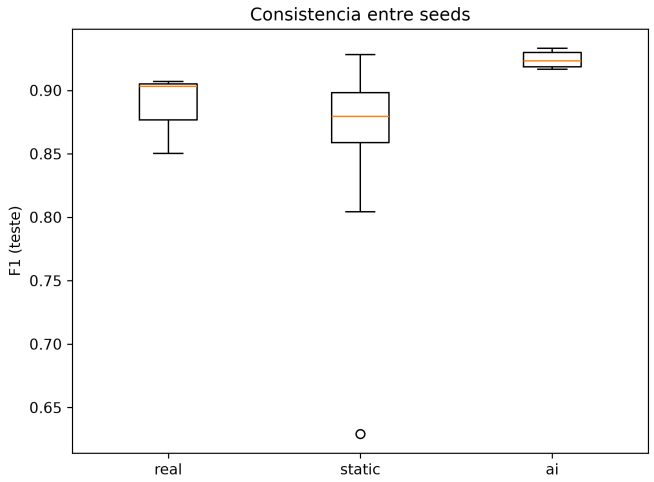


Fig. 6. Consistência entre sementes (boxplot de F1).

[6] I. Shumailov et al., "AI models collapse when trained on recursively generated data," *Nature*, vol. 631, 2024.

[7] A. Alaa, B. van Breugel, E. Saveliev, and M. van der Schaar, "How faithful is your synthetic data? Sample-level metrics for evaluating and auditing generative models," in *Proc. ICML*, 2022.

REFERENCES

[1] M. D. de Souza and C. Zanchettin, "Breaking the Barrier of Hard Samples: A Data-Centric Approach to Synthetic Data for Medical Tasks," in *Proc. ICML*, 2025.

[2] N. Seedat, J. Crabbé, and M. van der Schaar, "Data-IQ: Characterizing subgroups with heterogeneous outcomes in tabular data," in *Proc. NeurIPS*, 2022.

[3] R. Monteiro, R. Santos, T. Pardo, T. de Almeida, E. Ruiz, and O. Vale, "Contributions to the study of fake news in Portuguese: New corpus and automatic detection results," in *Proc. PROPOR*, 2018.

[4] F. Souza, R. Nogueira, and R. Lotufo, "BERTimbau: Pretrained BERT models for Brazilian Portuguese," in *Proc. BRACIS*, 2020.

[5] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," in *Proc. EMNLP*, 2019.

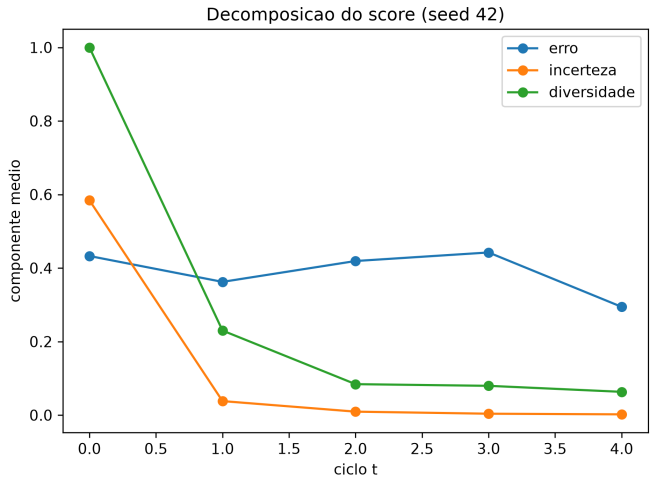


Fig. 7. Decomposição do escore (erro, incerteza, diversidade) por ciclo.