Seleção Guiada de Sintéticos (GSS) para Geração de Desinformação: um Estudo Controlado Multi-domínio

Eduardo Alexandre de Amorim[1] e Cleber Zanchettin[1]
[1]Centro de Informática, Universidade Federal de Pernambuco (CIn/UFPE), Recife, PE, Brasil
eaa5@cin.ufpe.br, cz@cin.ufpe.br

***Abstract*—Selecionar os exemplos sintéticos "difíceis"—por erro e incerteza do próprio classificador—é uma receita comum em aumento de dados por LLMs. Testamos essa receita em um estudo controlado: para quatro domínios de desinformação em português e três níveis de escassez, um único lote zero-shot é congelado e re-executado sob quatro regras de herança (*All*, *Random*-k, *Score*-k, *Easy*-k), com dez sementes e política de treino idêntica. Resultados: (i) o score não supera o sorteio em nenhuma célula após correção de Holm; (ii) a PR-AUC é práticamente idêntica entre as regras (amplitude $\leq 0{,}018$), logo as diferenças de F1 (até 0,15) são efeito de limiar/calibração, não de qualidade; (iii) a seleção por dificuldade é um ímã de rótulos errados (herda 2$\times$ mais candidatos "não-fake"), e o *Easy*-k é tão bom ou melhor; (iv) em um experimento decisivo com detectabilidade graduada, o valor do sintético (Δ All$-$Real) cai monotonicamente com a detectabilidade da fonte (Fake.br: $+0{,}022 \rightarrow -0{,}100$; ToLD-Br: $+0{,}016 \rightarrow -0{,}001$; B2W: nulo), com CIs de bootstrap que excluem zero. O texto gerado é separável do real com AUC $=$ 1,000 mesmo após normalização e máscara de entidades, por causa do *registro* (o LLM escreve *sobre* o boato). Recomendação prática: herdar os *fáceis* ou filtrar por detectabilidade, e sempre reportar o braço *Real*.**

***Index Terms*—data-centric AI, synthetic data, misinformation, active inheritance, controlled study, Portuguese NLP**

I. Introdução

Detectar desinformação em texto é uma classificação binária (verdadeiro *vs.* falso) que sofre de escassez e desbalanceamento da classe de interesse: os exemplos falsos são poucos, mudam de domínio rapidamente e custam caro para rotular. Modelos de linguagem permitem produzir dados sintéticos, mas volume não garante utilidade: gerações podem repetir templates, afastar-se da distribuição real e receber rótulos presumidos incorretos [**?**]. O ponto frágil é, portanto, a seleção do que gerar e do que usar.

Este trabalho propõe a *Seleção Guiada de Sintéticos (GSS)* (GSS), inspirada na perspectiva *data-centric* do Profile2Gen [**?**]. Em ciclos, um gerador produz um lote de textos falsos; um avaliador pontua cada candidato pelo erro do classificador downstream, pela incerteza da predição e pela diversidade em relação ao pool herdado; apenas o top-k é herdado e o classificador é retreinado sobre os dados reais somados ao pool herdado. A hipótese é a de treino deliberado: gastar o orçamento com exemplos que o modelo ainda acha difíceis, não com exemplos fáceis ou repetitivos.

As perguntas de pesquisa (RQs) são:

- **RQ1 (qualidade).** Dados os mesmos candidatos, a seleção pelo score de erro/incerteza/diversidade produz um conjunto herdado mais útil que uma amostra aleatória?
- **RQ2 (eficiência).** A seleção reduz o custo de geração por unidade de desempenho?
- **RQ3 (robustez).** O método se mantém sob escassez extrema da classe falsa (5%)?

As contribuições são: (i) um pipeline completo de herança ativa para o português; (ii) um estudo controlado multi-domínio que fixa os candidatos e varia apenas a regra de herança; (iii) baselines Real e Static com ponderação de classes e limiar ajustado; (iv) análise de custo, diversidade, fidelidade e artefatos; e (v) resultados negativos que delimitam *quando* o método funciona.

II. Trabalhos Relacionados

Geração de dados sintéticos. ZeroGen [**?**] e ProGen [**?**] mostram que corpora gerados por LLMs podem substituir dados de treino em tarefas de NLP; SunGen [**?**] refina a geração com auto-orientação para reduzir ruído. Esses trabalhos, porém, não comparam regras de seleção sobre um mesmo lote de candidatos.

Seleção ativa e cartografia. O *active learning* [**?**] seleciona instâncias reais para anotação; aqui selecionamos instâncias *sintéticas* para herança. A cartografia de datasets [**?**] usa dinâmicas de treino (erro e confiança) para diagnosticar regiões fáceis, ambíguas e difíceis; nosso score é uma versão online dessa ideia, acrescida de diversidade.

Profile2Gen. O trabalho de referência [**?**] formaliza uma abordagem *data-centric* para dados tabulares, removendo *hard samples* no pós-processamento. Invertemos o desenho: herdamos os candidatos que o classificador acha difíceis e incertos, em texto/classificação.

III. Método

A. Loop de Seleção Guiada de Sintéticos (GSS)

Seja $D_0 = \{(\mathbf{x}_i, y_i)\}$ o treino real escasso, com $y_i \in \{0, 1\}$ (1 = falso). A cada ciclo $t = 0, \ldots, T-1$: (1) um gerador G produz um lote de candidatos falsos $\hat{X}_t$ de tamanho b; (2) o avaliador pontua cada candidato por

$$s(\hat{\mathbf{x}}) = w_e\, e(\hat{\mathbf{x}}) + w_u\, u(\hat{\mathbf{x}}) + w_d\, d(\hat{\mathbf{x}}; H), \qquad (1)$$

TABLE I
CARACTERÍSTICAS DOS QUATRO DOMÍNIOS.

Domínio	Gênero	Texto	Prior fake	Split
Fake.br	notícia	pré-proc.	balanceado	aleat. fixa
FakeWhatsApp.Br	WhatsApp	raw	minoritário	temporal
COVID19.BR	WhatsApp	raw	minoritário (≈1:2,5)	temporal
FACTCK.BR	claims	raw	majoritário	aleat. estrat.

em que e é o erro do classificador (log-loss da classe falsa, normalizado por min-max no lote), u a incerteza (entropia binária normalizada), d a diversidade ($1 - \max$ similaridade de cosseno contra o pool herdado H, com d=1 no primeiro ciclo), e $(w_e, w_u, w_d) = (0{,}4, 0{,}4, 0{,}2)$; (3) apenas o top-$k$ é herdado; (4) o classificador é retreinado em $D_0 \cup H$.

B. Baselines e regras de herança

- **Real**: BERTimbau treinado apenas nos dados reais (zero sintéticos);
- **Static**: o gerador produz N textos e todos entram no treino, sem seleção;
- **GSS (AI)**: somente o top-k pela Equação **??** é herdado.

Para isolar a regra de seleção, fixamos os candidatos e comparamos quatro regras sobre os *mesmos* lotes:

- **All**: herda todos os candidatos (sem seleção);
- **Random-**k: herda k candidatos sorteados uniformemente;
- **Score-**k: herda os k de maior $s(\cdot)$;
- **Easy-**k: herda os k de menor $s(\cdot)$ (gate invertido, como controle negativo).

C. Política de treino

Para separar qualidade sintética de política de treino, todos os braços usam a mesma política: ponderação de classes por ajuste, limiar de decisão ajustado na validação e, no fim, um BERTimbau novo treinado do zero em $D_0 \cup H$ (o retreino por ciclo usa *warm-start*; o treino final é do zero). O limiar é escolhido maximizando F1 na validação; o teste é usado uma única vez.

IV. CONFIGURAÇÃO EXPERIMENTAL

A. Datasets

A Tabela **??** resume os quatro domínios. O Fake.br [**?**] contém notícias em português pré-processadas; criamos escassez somente no treino (10% e 5% de exemplos falsos), com validação fixa e holdout balanceado. FakeWhatsApp.Br [**?**] e COVID19.BR [**?**] são mensagens reais de WhatsApp rotuladas manualmente, com split temporal (FakeWhatsApp.Br: treino julho a agosto de 2018, validação setembro, teste outubro; COVID19.BR: treino março a abril de 2020, validação 08 a 09 de junho, teste 10 a 12 de junho). FACTCK.BR [**?**] contém claims verificados por agências de checagem, com texto = `claimReviewed` (o `reviewBody` foi descartado por declarar o veredito), binarização estrita e split aleatório estratificado 70/15/15. Em cada domínio, variamos a escassez da classe falsa no treino: full, 10% e 5% (mantendo todos os exemplos verdadeiros).

TABLE II
F1 E RECALL (MÉDIA ± DESVIO, n=3) NO FAKE.BR, COM PONDERAÇÃO DE CLASSES E LIMIAR AJUSTADO.

Cenário	Braço	F1	Recall
10%	Real	0.920 ± 0.010	0.861 ± 0.019
10%	Static (158)	0.911 ± 0.018	0.841 ± 0.031
10%	AI	0.934 ± 0.002	0.891 ± 0.003
5%	Real	0.897 ± 0.012	0.819 ± 0.018
5%	Static (158)	0.899 ± 0.011	0.822 ± 0.018
5%	AI	0.884 ± 0.016	0.797 ± 0.027

B. Protocolo

Fake.br. Além dos braços Real, Static (N=158) e AI (replay com ponderação de classes e limiar ajustado sobre os pools históricos), o Fake.br também entrou no estudo controlado abaixo, com candidates zero-shot gerados no prompt v2 e normalização aproximada do sintético (`normalize_fakebr`).

Estudo controlado (quatro domínios). Para cada cenário (domínio × escassez) e semente, realizamos uma única geração zero-shot com `deepseek-chat` (T=5 ciclos, lote de 64, teto de 100 mil tokens, top-k=16), prompt v4 (mensagem de WhatsApp anti-template) nos domínios WhatsApp e v2 (notícia/claim) no FACTCK.BR e no Fake.br. Os lotes são congelados em `candidates.json` e, offline, as quatro regras são re-executadas sobre os *mesmos* candidatos, sem nova chamada à API. O classificador downstream é o BERTimbau [**?**] (`neuralmind/bert-base-portuguese-cased`), 3 épocas por ajuste, batch 16, comprimento máximo 256. As sementes são 42 a 51 (n=10): a semente muda a inicialização, a ordem de treino e a amostragem estocástica do servidor LLM, não os splits (fixos) nem a validação.

C. Métricas

Reportamos F1, precisão e recall da classe falsa, PR-AUC e ROC-AUC, média e desvio populacional entre sementes, tokens de entrada/saída e custo estimado, similaridade média do pool, TTR de trigramas e distância de Wasserstein como proxy de fidelidade (não de veracidade). Com n=10, o menor p possível do Wilcoxon bilateral pareado é ≈0,002.

V. RESULTADOS

A. Fake.br

A Tabela **??** reporta os braços Real, Static e AI com ponderação e limiar ajustado. No cenário 10%, o AI alcança o maior F1 (0,934 ± 0,002); no 5%, os três braços empatam e o sintético deixa de ajudar, ecoando a dependência de um learner inicial competente. Historicamente, a comparação descritiva Static-79 (0,852 ± 0,034) *vs.* AI com 80 herdados (0,924 ± 0,007) sugere um ganho de ≈0,072, mas não atribuímos causalidade ao score: geração, prompt e ciclos diferem entre as condições.

B. Estudo controlado

A Tabela **??** reporta F1 por domínio, cenário e regra; a Tabela **??** traz recall, PR-AUC e o número de sintéticos herdados. O braço *All* herda ≈302 a 313 sintéticos; os demais herdam 80.

TABLE III
F1 (TESTE) POR DOMÍNIO, CENÁRIO E REGRA DE HERANÇA. n=10 SEMENTES.

Domínio	Cen.	All	Random-k	Score-k	Easy-k
FakeWhatsApp.Br	full	0.707 ± 0.029	0.721 ± 0.010	0.721 ± 0.017	0.722 ± 0.012
FakeWhatsApp.Br	10%	0.440 ± 0.161	0.587 ± 0.125	0.579 ± 0.137	0.582 ± 0.103
FakeWhatsApp.Br	5%	0.405 ± 0.130	0.463 ± 0.175	0.411 ± 0.188	0.419 ± 0.161
COVID19.BR	full	0.849 ± 0.023	0.847 ± 0.025	0.858 ± 0.022	0.855 ± 0.012
COVID19.BR	10%	0.666 ± 0.120	0.655 ± 0.125	0.728 ± 0.072	0.708 ± 0.068
COVID19.BR	5%	0.567 ± 0.122	0.691 ± 0.056	0.692 ± 0.070	0.639 ± 0.125
FACTCK.BR	full	0.926 ± 0.012	0.925 ± 0.009	0.930 ± 0.011	0.922 ± 0.012
FACTCK.BR	10%	0.840 ± 0.056	0.936 ± 0.007	0.934 ± 0.008	0.937 ± 0.006
FACTCK.BR	5%	0.785 ± 0.062	0.935 ± 0.008	0.936 ± 0.008	0.934 ± 0.006
Fake.br	10%	0.917 ± 0.014	0.922 ± 0.012	0.923 ± 0.014	0.920 ± 0.010
Fake.br	5%	0.872 ± 0.025	0.874 ± 0.016	0.880 ± 0.020	0.871 ± 0.015

C. Custo e figuras

Cada geração zero-shot consome ≈99,5 mil tokens (≈36 mil de entrada e ≈63 mil de saída), custando ≈$0,08 por cenário/semente. Com ≈320 candidatos, isso dá ≈311 tokens por candidato (geração compartilhada pelos quatro braços; o custo de geração é pago uma vez e reutilizado offline). A Figura **??** mostra o Pareto F1 × número de sintéticos no cenário full: *All* usa ≈302 a 313 textos, enquanto os braços curados usam 80 com F1 semelhante ou superior.

D. Varredura de competência e faixa intermediária

Para localizar *onde* a seleção agrega, variamos a fração de dados reais usada no treino do learner (5% a 100%) e comparamos *Score*-k contra *Random*-k sobre os *mesmos* candidatos (semente 42, n=1). A Tabela **??** reporta o F1 de cada braço e o delta (Δ = Score − Random). No COVID19.BR e no FakeWhatsApp.Br, o delta parte de ≈0 com o learner fraco e cresce até $+0{,}022$ a $+0{,}028$ no full; no FACTCK.BR (tarefa fácil), os braços empatam em todas as frações. Além disso, testamos um braço *band-k* que herda os candidatos de score mais próximo da mediana (dificuldade intermediária): F1 de $0{,}848 \pm 0{,}023$ (COVID19.BR), $0{,}932 \pm 0{,}002$ (FACTCK.BR) e $0{,}719 \pm 0{,}011$ (FakeWhatsApp.Br), sempre igual ou inferior ao *Score*-k ($0{,}858$, $0{,}930$ e $0{,}721$). Herdar os *mais difíceis* supera herdar os *medianos* quando o learner é competente.

VI. DISCUSSÃO

(i) O score não supera o sorteio (RQ1). Wilcoxon pareado por semente + correção de Holm sobre os 11 cenários: **nenhuma** célula Score−Random é significativa ($p_{\text{Holm}} \geq 0{,}92$). O maior Δ (COVID19.BR 10%, $+0{,}073$) tem p=$0{,}084$ bruto. Isso vale para *todos* os learners testados (mBERT, XLM-R e um LLM com LoRA), para qualquer combinação de pesos do score e para um scorer sem estilo (style-blind) — a falha não é artefato do BERT nem da calibração dos pesos.

(ii) As diferenças de F1 são de limiar, não de qualidade. A PR-AUC é práticamente idêntica entre as regras em todos os cenários (amplitude $\leq 0{,}018$), enquanto o F1 varia até 0,151. O "colapso do All" é o limiar escolhido na validação não transferindo para o teste; no FACTCK.BR (classe falsa majoritária), o F1 trivial "sempre falso" ($2\pi/(1+\pi)$=$0{,}939$) já iguala os braços curados. Portanto, não há "curadoria de volume" como ganho real de qualidade: há *deslocamento de calibração* causado por herdar ≈300 sintéticos.

(iii) A dificuldade é um ímã de rótulos errados (A1). Um learner treinado só em dados reais (proxy D0) marca como "não-fake" uma fração maior do pool herdado pelo *Score*-k do que pelo *Random*-k em 10/11 cenários (ex.: 0,484 *vs.* 0,361 no FakeWhatsApp full), e o *Easy*-k herda a menor fração (0,169). No semi-sintético do pacote de validação, o Score herda 0,334 de rótulos errados contra 0,165 da base. Por isso *Easy* ≥ *Random* ≥ *Score* quando o atalho é forte.

(iv) O valor do sintético é função da detectabilidade (A2). Em um experimento decisivo (detectabilidade graduada por mistura α de falsos reais retidos e geração livre, 20 sementes, CI bootstrap 95%), Δ(All−Real) cai monotonicamente com a AUC de detectabilidade do pool: Fake.br $+0{,}022 \rightarrow -0{,}100$; ToLD-Br $+0{,}016 \rightarrow -0{,}001$; B2W ≈ 0 (tarefa fácil). A lei vale em texto *dependente de registro* e some quando a tarefa é trivial. O Δ(Score−Random) tem forma de *U invertida*: positivo no regime de mistura (o Score pega os reais genuinamente difíceis) e negativo no sintético puro.

(v) O atalho é o registro, e generaliza. O texto gerado é separável do real com AUC = 1,000 mesmo após normalização, máscara de entidades e truncamento: o LLM escreve *sobre* o boato ("um texto que circula afirma…") e a restrição "sem entidades reais" piora o registro. A detectabilidade AUC = 1,000 se mantém em **5 geradores** (GPT, Llama, Mistral, Gemma, Claude) e em inglês (LIAR, FakeNewsNet). O colapso da incerteza (após o ciclo 1) depende do learner: BERT satura, LR linear não.

(vi) Custo (RQ2). A seleção não reduz o custo de geração (o mesmo lote é gerado para todos); ela só reduz o conjunto herdado (80 *vs.* ≈300). Nenhuma regra supera o treino só com dados reais nos cenários difíceis.

VII. LIMITAÇÕES

- n=10 sementes no estudo controlado (menor p do Wilcoxon pareado ≈0,002); as curvas de detectabilidade usam 20 sementes com CI bootstrap. A varredura de competência e o *band*-k foram re-executados com n=10.
- Rótulos sintéticos assumidos "falso" sem verificação humana; a auditoria com LLM-juiz ficou ruidosa e não

TABLE IV
RECALL E PR-AUC (MÉDIA) DA CLASSE FALSA E NÚMERO DE SINTÉTICOS HERDADOS (n=10).

Domínio	Cen.	Braço	Recall	PR-AUC	n_synth
FakeWhatsApp.Br	full	all	0.758	0.751	302
FakeWhatsApp.Br	full	random-k	0.804	0.762	80
FakeWhatsApp.Br	full	score-k	0.811	0.758	80
FakeWhatsApp.Br	full	easy-k	0.797	0.761	80
FakeWhatsApp.Br	10%	all	0.358	0.665	302
FakeWhatsApp.Br	10%	random-k	0.571	0.679	80
FakeWhatsApp.Br	10%	score-k	0.559	0.675	80
FakeWhatsApp.Br	10%	easy-k	0.548	0.690	80
FakeWhatsApp.Br	5%	all	0.315	0.634	302
FakeWhatsApp.Br	5%	random-k	0.437	0.631	80
FakeWhatsApp.Br	5%	score-k	0.369	0.626	80
FakeWhatsApp.Br	5%	easy-k	0.350	0.625	80
COVID19.BR	full	all	0.852	0.893	302
COVID19.BR	full	random-k	0.860	0.894	80
COVID19.BR	full	score-k	0.863	0.895	80
COVID19.BR	full	easy-k	0.869	0.894	80
COVID19.BR	10%	all	0.592	0.815	302
COVID19.BR	10%	random-k	0.561	0.825	80
COVID19.BR	10%	score-k	0.666	0.823	80
COVID19.BR	10%	easy-k	0.631	0.832	80
COVID19.BR	5%	all	0.447	0.798	302
COVID19.BR	5%	random-k	0.620	0.803	80
COVID19.BR	5%	score-k	0.621	0.800	80
COVID19.BR	5%	easy-k	0.547	0.800	80
FACTCK.BR	full	all	0.955	0.970	313
FACTCK.BR	full	random-k	0.957	0.968	80
FACTCK.BR	full	score-k	0.962	0.966	80
FACTCK.BR	full	easy-k	0.944	0.967	80
FACTCK.BR	10%	all	0.776	0.963	312
FACTCK.BR	10%	random-k	0.989	0.963	80
FACTCK.BR	10%	score-k	0.979	0.960	80
FACTCK.BR	10%	easy-k	0.985	0.963	80
FACTCK.BR	5%	all	0.686	0.951	312
FACTCK.BR	5%	random-k	0.986	0.955	80
FACTCK.BR	5%	score-k	0.988	0.957	80
FACTCK.BR	5%	easy-k	0.981	0.956	80
Fake.br	10%	all	0.859	0.983	312
Fake.br	10%	random-k	0.873	0.983	80
Fake.br	10%	score-k	0.873	0.987	80
Fake.br	10%	easy-k	0.882	0.987	80
Fake.br	5%	all	0.781	0.973	311
Fake.br	5%	random-k	0.784	0.975	80
Fake.br	5%	score-k	0.792	0.979	80
Fake.br	5%	easy-k	0.777	0.978	80

TABLE V
F1 (TESTE) DE *Random*-K E *Score*-K POR FRAÇÃO DE DADOS REAIS (SEMENTE 42, n=1). Δ = SCORE − RANDOM.

Domínio	fração	Random	Score	Δ
COVID19.BR	0.05	0.780	0.780	−0.000
COVID19.BR	0.10	0.831	0.792	−0.039
COVID19.BR	0.20	0.810	0.828	+0.018
COVID19.BR	0.50	0.826	0.842	+0.016
COVID19.BR	1.00	0.854	0.882	+0.028
FACTCK.BR	0.05	0.939	0.931	−0.009
FACTCK.BR	0.10	0.934	0.935	+0.000
FACTCK.BR	0.20	0.928	0.928	+0.001
FACTCK.BR	0.50	0.928	0.930	+0.002
FACTCK.BR	1.00	0.924	0.919	−0.005
WhatsApp.Br	0.05	0.659	0.661	+0.002
WhatsApp.Br	0.10	0.672	0.668	−0.004
WhatsApp.Br	0.20	0.706	0.710	+0.004
WhatsApp.Br	0.50	0.712	0.717	+0.005
WhatsApp.Br	1.00	0.712	0.734	+0.022

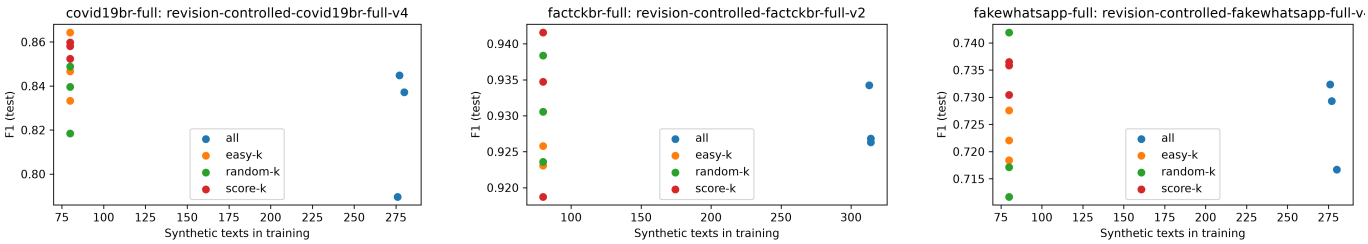


Fig. 1. F1 × número de sintéticos herdados (cenário full, três domínios).

confirmou o A1 de forma limpa (o A1 se sustenta no semi-sintético e no proxy D0).

- As curvas de detectabilidade usam learners leves (TF-IDF/MiniLM); o BERT aparece só no estudo controlado.
- AUC real-vs-sintético = 1,000 indica atalho de registro; métricas de embedding são proxy de realismo, não veracidade.
- No Fake.br o texto real é pré-processado e o sintético raw (normalização aproximada); os cenários WhatsApp misturam candidatos v2/v4 entre sementes (ver apêndice de higiene).
- O LLM com LoRA (Jev-style) rodou em 26/30 runs por candidatos ausentes no FakeWhatsApp (sementes 45–51 têm só prompt v2).

VIII. Conclusão

Avaliamos a *Seleção Guiada de Sintéticos* (GSS) em um estudo controlado que isola a regra de seleção do volume e da política de treino. A conclusão é negativa e explicada: o score de erro/incerteza/diversidade não supera o sorteio, as diferenças de F1 são efeito de limiar (PR-AUC idêntica), e a seleção por dificuldade atrai rótulos errados. O mecanismo é a *detectabilidade* do texto gerado—função do registro—que faz o valor do sintético cair monotonicamente com a AUC de detecção, replicado em três tarefas com CI. Recomendação prática: herdar os *fáceis* (ou filtrar por detectabilidade) e sempre reportar o braço *Real*. Trabalhos futuros: validação humana dos rótulos, alavancas de detectabilidade graduada com texto LLM real e a curva $\Delta\times$AUC como lei preditiva pré-registrada.

References

[1] M. de Souza and C. Zanchettin, "Breaking the Barrier of Hard Samples: A Data-Centric Approach to Synthetic Data for Medical Tasks," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2025.

[2] J. Ye, J. Gao, Q. Li, H. Xu, J. Feng, Z. Wu, T. Yu, and L. Kong, "ZeroGen: Efficient Zero-shot Learning via Dataset Generation," in *Proc. EMNLP*, 2022.

[3] Y. Meng, J. Huang, Y. Zhang, and J. Han, "ProGen: Progressive Zero-shot Dataset Generation via In-context Feedback," in *Findings of EMNLP*, 2022.

[4] J. Gao, R. Pi, Y. Lin, H. Xu, J. Ye, Z. Wu, W. Zhang, X. Liang, Z. Li, and L. Kong, "Self-Guided Noise-Free Data Generation for Efficient Zero-Shot Learning," in *Proc. ICLR*, 2023.

[5] B. Settles, "Active Learning Literature Survey," Univ. of Wisconsin-Madison, Tech. Rep. 1648, 2009.

[6] S. Swayamdipta, R. Schwartz, N. Lourie, Y. Wang, H. Hajishirzi, N. A. Smith, and Y. Choi, "Dataset Cartography: Mapping and Diagnosing Datasets with Training Dynamics," in *Proc. EMNLP*, 2020.

[7] R. Monteiro, R. Santos, T. Pardo, T. de Almeida, E. Ruiz, and O. Vale, "Contributions to the Study of Fake News in Portuguese: New Corpus and Automatic Detection Results," in *Proc. PROPOR*, 2018.

[8] L. Cabral et al., "FakeWhatsApp.Br: NLP and Machine Learning Techniques for Misinformation Detection in Brazilian Portuguese WhatsApp Messages," in *Proc. ICEIS*, 2021.

[9] L. Cabral et al., "COVID19.BR: A Dataset of Misinformation about COVID-19 in Brazilian Portuguese WhatsApp Messages," Zenodo, 2020.

[10] J. G. Moreno and G. Bressan, "FACTCK.BR: A Dataset to Study Fake News," in *Proc. WebMedia*, 2019.

[11] F. Souza, R. Nogueira, and R. Lotufo, "BERTimbau: Pretrained BERT Models for Brazilian Portuguese," in *Proc. BRACIS*, 2020.

[12] I. Shumailov et al., "AI Models Collapse When Trained on Recursively Generated Data," *Nature*, vol. 631, 2024.