Herança Ativa para Geração Sintética de Desinformação: um Estudo Controlado Multi-domínio

Eduardo Alexandre de Amorim[1] e Cleber Zanchettin[1]
[1]Centro de Informática, Universidade Federal de Pernambuco (CIn/UFPE), Recife, PE, Brasil
eaa5@cin.ufpe.br, cz@cin.ufpe.br

***Abstract*—A escassez de exemplos rotulados de desinformação limita classificadores robustos, enquanto a geração sintética indiscriminada pode introduzir redundância, artefatos e ruído. Este trabalho propõe a *Herança Ativa* (ActiveInheritance): um processo cíclico em que um modelo de linguagem gera candidatos falsos e um avaliador adversarial, que combina o erro, a incerteza e a diversidade do classificador downstream, seleciona apenas o top-k para ser herdado no ciclo seguinte de treino. Para isolar o efeito da regra de seleção do volume gerado e da política de treino, conduzimos um estudo controlado em quatro domínios do português (Fake.br, FakeWhatsApp.Br, COVID19.BR e FACTCK.BR). Nos três domínios novos, uma única geração zero-shot por cenário e semente é re-executada offline com quatro regras de herança: herdar tudo (*All*), uma amostra aleatória (*Random*-k), o score top-k (*Score*-k) e o gate invertido (*Easy*-k), em três níveis de escassez e três sementes (108 runs). Os resultados mostram que o score não domina a seleção aleatória, que o efeito observado é sobretudo curadoria de volume, e que a seleção guiada só agrega em regimes de dificuldade intermediária; a ponderação de classes e o limiar ajustado respondem pela maior parte do ganho. Além disso, um classificador linear distingue o texto sintético do real com AUC = 1,000, indicando um atalho estilístico que a seleção não elimina.**

***Index Terms*—data-centric AI, synthetic data, misinformation, active inheritance, controlled study, Portuguese NLP**

I. Introdução

Detectar desinformação em texto é uma classificação binária (verdadeiro *vs.* falso) que sofre de escassez e desbalanceamento da classe de interesse: os exemplos falsos são poucos, mudam de domínio rapidamente e custam caro para rotular. Modelos de linguagem permitem produzir dados sintéticos, mas volume não garante utilidade: gerações podem repetir templates, afastar-se da distribuição real e receber rótulos presumidos incorretos [12]. O ponto frágil é, portanto, a seleção do que gerar e do que usar.

Este trabalho propõe a *Herança Ativa* (ActiveInheritance), inspirada na perspectiva *data-centric* do Profile2Gen [1]. Em ciclos, um gerador produz um lote de textos falsos; um avaliador pontua cada candidato pelo erro do classificador downstream, pela incerteza da predição e pela diversidade em relação ao pool herdado; apenas o top-k é herdado e o classificador é retreinado sobre os dados reais somados ao pool herdado. A hipótese é a de treino deliberado: gastar o orçamento com exemplos que o modelo ainda acha difíceis, não com exemplos fáceis ou repetitivos.

As perguntas de pesquisa (RQs) são:

- **RQ1 (qualidade).** Dados os mesmos candidatos, a seleção pelo score de erro/incerteza/diversidade produz um conjunto herdado mais útil que uma amostra aleatória?
- **RQ2 (eficiência).** A seleção reduz o custo de geração por unidade de desempenho?
- **RQ3 (robustez).** O método se mantém sob escassez extrema da classe falsa (5%)?

As contribuições são: (i) um pipeline completo de herança ativa para o português; (ii) um estudo controlado multi-domínio que fixa os candidatos e varia apenas a regra de herança; (iii) baselines Real e Static com ponderação de classes e limiar ajustado; (iv) análise de custo, diversidade, fidelidade e artefatos; e (v) resultados negativos que delimitam *quando* o método funciona.

II. Trabalhos Relacionados

Geração de dados sintéticos. ZeroGen [2] e ProGen [3] mostram que corpora gerados por LLMs podem substituir dados de treino em tarefas de NLP; SunGen [4] refina a geração com auto-orientação para reduzir ruído. Esses trabalhos, porém, não comparam regras de seleção sobre um mesmo lote de candidatos.

Seleção ativa e cartografia. O *active learning* [5] seleciona instâncias reais para anotação; aqui selecionamos instâncias *sintéticas* para herança. A cartografia de datasets [6] usa dinâmicas de treino (erro e confiança) para diagnosticar regiões fáceis, ambíguas e difíceis; nosso score é uma versão online dessa ideia, acrescida de diversidade.

Profile2Gen. O trabalho de referência [1] formaliza uma abordagem *data-centric* para dados tabulares, removendo *hard samples* no pós-processamento. Invertemos o desenho: herdamos os candidatos que o classificador acha difíceis e incertos, em texto/classificação.

III. Método

A. Loop de Herança Ativa

Seja $D_0 = \{(\mathbf{x}_i, y_i)\}$ o treino real escasso, com $y_i \in \{0, 1\}$ (1 = falso). A cada ciclo $t = 0, \ldots, T-1$: (1) um gerador G produz um lote de candidatos falsos $\hat{X}_t$ de tamanho b; (2) o avaliador pontua cada candidato por

$$s(\hat{\mathbf{x}}) = w_e\, e(\hat{\mathbf{x}}) + w_u\, u(\hat{\mathbf{x}}) + w_d\, d(\hat{\mathbf{x}}; H), \qquad (1)$$

em que e é o erro do classificador (log-loss da classe falsa, normalizado por min-max no lote), u a incerteza (entropia binária normalizada), d a diversidade ($1 - \max$ similaridade de cosseno contra o pool herdado H, com d=1 no primeiro ciclo), e $(w_e, w_u, w_d) = (0{,}4, 0{,}4, 0{,}2)$; (3) apenas o top-$k$ é herdado; (4) o classificador é retreinado em $D_0 \cup H$.

B. Baselines e regras de herança

- **Real**: BERTimbau treinado apenas nos dados reais (zero sintéticos);
- **Static**: o gerador produz N textos e todos entram no treino, sem seleção;
- **ActiveInheritance (AI)**: somente o top-k pela Equação 1 é herdado.

Para isolar a regra de seleção, fixamos os candidatos e comparamos quatro regras sobre os *mesmos* lotes:

- **All**: herda todos os candidatos (sem seleção);
- **Random-**k: herda k candidatos sorteados uniformemente;
- **Score-**k: herda os k de maior $s(\cdot)$;
- **Easy-**k: herda os k de menor $s(\cdot)$ (gate invertido, como controle negativo).

C. Política de treino

Para separar qualidade sintética de política de treino, todos os braços usam a mesma política: ponderação de classes por ajuste, limiar de decisão ajustado na validação e, no fim, um BERTimbau novo treinado do zero em $D_0 \cup H$ (o retreino por ciclo usa *warm-start*; o treino final é do zero). O limiar é escolhido maximizando F1 na validação; o teste é usado uma única vez.

IV. Configuração Experimental

A. Datasets

A Tabela I resume os quatro domínios. O Fake.br [7] contém notícias em português pré-processadas; criamos escassez somente no treino (10% e 5% de exemplos falsos), com validação fixa e holdout balanceado. FakeWhatsApp.Br [8] e COVID19.BR [9] são mensagens reais de WhatsApp rotuladas manualmente, com split temporal (FakeWhatsApp.Br: treino julho a agosto de 2018, validação setembro, teste outubro; COVID19.BR: treino março a abril de 2020, validação 08 a 09 de junho, teste 10 a 12 de junho). FACTCK.BR [10] contém claims verificados por agências de checagem, com texto = `claimReviewed` (o `reviewBody` foi descartado por declarar o veredito), binarização estrita e split aleatório estratificado 70/15/15. Em cada domínio, variamos a escassez da classe falsa no treino: full, 10% e 5% (mantendo todos os exemplos verdadeiros).

B. Protocolo

Fake.br (estudo original). Braços Real, Static (N=158) e AI, re-executados com ponderação de classes e limiar ajustado sobre os pools históricos (replay exploratório; o AI herda 80 textos).

TABLE I
Características dos quatro domínios.

Domínio	Gênero	Texto	Prior fake	Split
Fake.br	notícia	pré-proc.	balanceado	aleat. fixa
FakeWhatsApp.Br	WhatsApp	raw	minoritário	temporal
COVID19.BR	WhatsApp	raw	minoritário (≈1:2,5)	temporal
FACTCK.BR	claims	raw	majoritário	aleat. estrat.

TABLE II
F1 e recall (média ± desvio, n=3) no Fake.br, com ponderação de classes e limiar ajustado.

Cenário	Braço	F1	Recall
10%	Real	0.920 ± 0.010	0.861 ± 0.019
10%	Static (158)	0.911 ± 0.018	0.841 ± 0.031
10%	AI	0.934 ± 0.002	0.891 ± 0.003
5%	Real	0.897 ± 0.012	0.819 ± 0.018
5%	Static (158)	0.899 ± 0.011	0.822 ± 0.018
5%	AI	0.884 ± 0.016	0.797 ± 0.027

Estudo controlado (três domínios novos). Para cada cenário (domínio × escassez) e semente, realizamos uma única geração zero-shot com `deepseek-chat` (T=5 ciclos, lote de 64, teto de 100 mil tokens, top-k=16), prompt v4 (mensagem de WhatsApp anti-template) nos domínios WhatsApp e v2 (notícia fictícia) no FACTCK.BR. Os lotes são congelados em `candidates.json` e, offline, as quatro regras são re-executadas sobre os *mesmos* candidatos, sem nova chamada à API. O classificador downstream é o BERTimbau [11] (`neuralmind/bert-base-portuguese-cased`), 3 épocas por ajuste, batch 16, comprimento máximo 256. As sementes são 42 a 44 (n=3, exploratório): a semente muda a inicialização, a ordem de treino e a amostragem estocástica do servidor LLM, não os splits (fixos) nem a validação.

C. Métricas

Reportamos F1, precisão e recall da classe falsa, PR-AUC e ROC-AUC, média e desvio populacional entre sementes, tokens de entrada/saída e custo estimado, similaridade média do pool, TTR de trigramas e distância de Wasserstein como proxy de fidelidade (não de veracidade). Com n=3, o menor p possível do Wilcoxon bilateral é 0,25; os resultados são exploratórios e não declaramos significância.

V. Resultados

A. Fake.br

A Tabela II reporta os braços Real, Static e AI com ponderação e limiar ajustado. No cenário 10%, o AI alcança o maior F1 (0,934 ± 0,002); no 5%, os três braços empatam e o sintético deixa de ajudar, ecoando a dependência de um learner inicial competente. Historicamente, a comparação descritiva Static-79 (0,852 ± 0,034) *vs.* AI com 80 herdados (0,924 ± 0,007) sugere um ganho de ≈0,072, mas não atribuímos causalidade ao score: geração, prompt e ciclos diferem entre as condições.

B. Estudo controlado

A Tabela III reporta F1 por domínio, cenário e regra; a Tabela IV traz recall, PR-AUC e o número de sintéticos herdados. O braço *All* herda ≈277 a 313 sintéticos; os demais herdam 80.

C. Custo e figuras

Cada geração zero-shot consome ≈99,5 mil tokens (≈36 mil de entrada e ≈63 mil de saída), custando ≈$0,08 por cenário/semente. Com ≈320 candidatos, isso dá ≈311 tokens por candidato (geração compartilhada pelos quatro braços; o custo de geração é pago uma vez e reutilizado offline). A Figura 1 mostra o Pareto F1 × número de sintéticos no cenário full: *All* usa ≈277 a 313 textos, enquanto os braços curados usam 80 com F1 semelhante ou superior.

D. Varredura de competência e faixa intermediária

Para localizar *onde* a seleção agrega, variamos a fração de dados reais usada no treino do learner (5% a 100%) e comparamos *Score*-k contra *Random*-k sobre os *mesmos* candidatos (semente 42, n=1). A Tabela V reporta o F1 de cada braço e o delta (Δ = Score − Random). No COVID19.BR e no FakeWhatsApp.Br, o delta parte de ≈0 com o learner fraco e cresce até $+0{,}022$ a $+0{,}028$ no full; no FACTCK.BR (tarefa fácil), os braços empatam em todas as frações. Além disso, testamos um braço *band-k* que herda os candidatos de score mais próximo da mediana (dificuldade intermediária): F1 de $0{,}848 \pm 0{,}023$ (COVID19.BR), $0{,}932 \pm 0{,}002$ (FACTCK.BR) e $0{,}719 \pm 0{,}011$ (FakeWhatsApp.Br), sempre igual ou inferior ao *Score*-k (0,857, 0,932 e 0,734). Herdar os *mais difíceis* supera herdar os *medianos* quando o learner é competente.

VI. Discussão

(i) O score não domina o sorteio (RQ1). No COVID19.BR, *Score*-k só vence *Random*-k no full (0,857 *vs.* 0,836) e por margem pequena; sob escassez, *Random*-k empata ou vence. Nos demais domínios os braços empatam. Dados os mesmos candidatos, o score não agrega sobre uma amostra aleatória.

(ii) O efeito real é curadoria de volume, não o score. *All* herda 277 a 313 sintéticos; os demais, 80. Em escassez extrema (COVID19.BR 5%), *All* colapsa para F1 0,468 enquanto os curados ficam em 0,60 a 0,70. Herdar *menos*, mantendo o treino rebalanceado, importa mais do que *o quê* se herda.

(iii) O ganho do score cresce com a competência do learner. A Tabela V mostra que, no COVID19.BR e no FakeWhatsApp.Br, o delta Score − Random parte de ≈0 com 5% dos dados reais e sobe até $+0{,}022$ a $+0{,}028$ no full; no FACTCK.BR (tarefa fácil) fica ≈0 em todas as frações. O braço *band-k* (dificuldade intermediária) fica igual ou abaixo do *Score*-k nos três domínios. Ou seja: a herança guiada ajuda quando o learner inicial já é competente e a tarefa é difícil o bastante para haver margem; herdar os *mais difíceis* supera herdar os *medianos*.

(iv) Calibração faz o trabalho pesado. Os limiares caem para 0,05 a 0,11 na escassez: sem ponderação e limiar ajustado, o modelo subestima a classe minoritária e o recall colapsa. Parte do F1 observado é política de treino, não qualidade intrínseca do sintético.

(v) Custo (RQ2). A seleção não reduz o custo de geração: o mesmo lote é gerado para todos os braços. Ela reduz o tamanho do conjunto de treino herdado (80 *vs.* 277 a 313), mas não o orçamento de tokens.

(vi) Artefatos e fidelidade. No prompt anterior (v3), 91% a 93% dos sintéticos começavam por "URGENTE" e 85% a 86% continham "acabei de receber", contra ≈1% e ≈0% no real; a mensagem falsa real tem ≈159 palavras, contra 95 a 100 dos sintéticos. O prompt v4 foi desenhado para mitigar esses templates. Ainda assim, o Wasserstein do pool AI não melhora de forma consistente, e um classificador TF-IDF + regressão logística separa o texto sintético do real com AUC = 1,000 nos três domínios (split aleatório, diagnóstico): há um atalho estilístico que a diversidade dentro do pool não elimina.

(vii) Saturação da incerteza. A incerteza média dos lotes cai quase a zero após o primeiro ciclo: o learner aprende o estilo sintético e o termo de entropia deixa de contribuir, o que sustenta early stopping ou recalibração.

VII. Limitações

- n=3 sementes: poder estatístico insuficiente (menor p do Wilcoxon bilateral = 0,25); resultados exploratórios.
- Rótulos sintéticos assumidos como "falso" sem verificação factual humana; a veracidade exige evidência externa.
- AUC real-vs-sintético = 1,000 indica atalho estilístico; métricas de embedding são proxies, não realismo.
- No Fake.br, o texto real é pré-processado e o sintético é raw; a normalização aplicada é aproximada (análise de sensibilidade, não equivalência exata).
- FACTCK.BR usa split aleatório e prior invertido; COVID19.BR não tem maio/2020 e o teste é um futuro curto.
- A varredura de competência usou uma única semente (n=1); o braço *band-k* tem n=3. A seleção por faixa da probabilidade $p(\text{fake})$ não foi executada; o *band-k* seleciona pelo score mediano.
- Expansão para 10 sementes e checagem humana ficam como trabalho futuro.

VIII. Conclusão

Apresentamos a Herança Ativa e a avaliamos em um estudo controlado multi-domínio que isola a regra de seleção do volume gerado e da política de treino. A conclusão é negativa e informativa: dados os mesmos candidatos, o score de erro/incerteza/diversidade não supera consistentemente uma amostra aleatória; o ganho prático vem da curadoria de volume e da calibração. A varredura de competência confirma quantitativamente esse limite: o ganho do score sobre o sorteio cresce de ≈0 (5% dos dados reais) até $+0{,}022$ a $+0{,}028$ (full) nos domínios difíceis, e desaparece em tarefa fácil; herdar os mais difíceis supera herdar os medianos. Trabalhos futuros devem priorizar prompts que amostrem a distribuição real,

TABLE III
F1 (TESTE) POR DOMÍNIO, CENÁRIO E REGRA DE HERANÇA. n=3 SEMENTES.

Domínio	Cen.	All	Random-k	Score-k	Easy-k
FakeWhatsApp.Br	full	0.726 ± 0.007	0.724 ± 0.013	0.734 ± 0.003	0.723 ± 0.004
FakeWhatsApp.Br	10%	0.416 ± 0.130	0.561 ± 0.063	0.552 ± 0.045	0.519 ± 0.083
FakeWhatsApp.Br	5%	0.480 ± 0.161	0.607 ± 0.059	0.532 ± 0.107	0.576 ± 0.034
COVID19.BR	full	0.824 ± 0.024	0.836 ± 0.013	0.857 ± 0.003	0.848 ± 0.013
COVID19.BR	10%	0.789 ± 0.017	0.732 ± 0.049	0.805 ± 0.018	0.773 ± 0.041
COVID19.BR	5%	0.468 ± 0.029	0.704 ± 0.039	0.668 ± 0.062	0.601 ± 0.133
FACTCK.BR	full	0.929 ± 0.004	0.931 ± 0.006	0.932 ± 0.010	0.926 ± 0.003
FACTCK.BR	10%	0.816 ± 0.044	0.931 ± 0.011	0.934 ± 0.007	0.937 ± 0.008
FACTCK.BR	5%	0.765 ± 0.076	0.928 ± 0.010	0.935 ± 0.006	0.931 ± 0.006

TABLE IV
RECALL E PR-AUC (MÉDIA) DA CLASSE FALSA E NÚMERO DE SINTÉTICOS HERDADOS.

Domínio	Cen.	Braço	Recall	PR-AUC	n_synth
FakeWhatsApp.Br	full	all	0.820	0.762	277
FakeWhatsApp.Br	full	random-k	0.781	0.772	80
FakeWhatsApp.Br	full	score-k	0.818	0.769	80
FakeWhatsApp.Br	full	easy-k	0.778	0.766	80
FakeWhatsApp.Br	10%	all	0.308	0.662	277
FakeWhatsApp.Br	10%	random-k	0.488	0.676	80
FakeWhatsApp.Br	10%	score-k	0.471	0.660	80
FakeWhatsApp.Br	10%	easy-k	0.439	0.672	80
FakeWhatsApp.Br	5%	all	0.416	0.636	276
FakeWhatsApp.Br	5%	random-k	0.628	0.641	80
FakeWhatsApp.Br	5%	score-k	0.493	0.638	80
FakeWhatsApp.Br	5%	easy-k	0.523	0.648	80
COVID19.BR	full	all	0.802	0.886	277
COVID19.BR	full	random-k	0.822	0.897	80
COVID19.BR	full	score-k	0.871	0.901	80
COVID19.BR	full	easy-k	0.853	0.907	80
COVID19.BR	10%	all	0.791	0.853	278
COVID19.BR	10%	random-k	0.653	0.848	80
COVID19.BR	10%	score-k	0.789	0.853	80
COVID19.BR	10%	easy-k	0.731	0.861	80
COVID19.BR	5%	all	0.322	0.792	278
COVID19.BR	5%	random-k	0.660	0.818	80
COVID19.BR	5%	score-k	0.591	0.801	80
COVID19.BR	5%	easy-k	0.498	0.806	80
FACTCK.BR	full	all	0.959	0.971	313
FACTCK.BR	full	random-k	0.969	0.968	80
FACTCK.BR	full	score-k	0.966	0.965	80
FACTCK.BR	full	easy-k	0.952	0.967	80
FACTCK.BR	10%	all	0.734	0.961	312
FACTCK.BR	10%	random-k	0.978	0.961	80
FACTCK.BR	10%	score-k	0.986	0.961	80
FACTCK.BR	10%	easy-k	0.986	0.963	80
FACTCK.BR	5%	all	0.657	0.952	312
FACTCK.BR	5%	random-k	0.969	0.955	80
FACTCK.BR	5%	score-k	0.988	0.957	80
FACTCK.BR	5%	easy-k	0.978	0.960	80

TABLE V
F1 (TESTE) DE *Random*-K E *Score*-K POR FRAÇÃO DE DADOS REAIS (SEMENTE 42, n=1). Δ = SCORE − RANDOM.

Domínio	fração	Random	Score	Δ
COVID19.BR	0.05	0.780	0.780	−0.000
COVID19.BR	0.10	0.831	0.792	−0.039
COVID19.BR	0.20	0.810	0.828	+0.018
COVID19.BR	0.50	0.826	0.842	+0.016
COVID19.BR	1.00	0.854	0.882	+0.028
FACTCK.BR	0.05	0.939	0.931	−0.009
FACTCK.BR	0.10	0.934	0.935	+0.000
FACTCK.BR	0.20	0.928	0.928	+0.001
FACTCK.BR	0.50	0.928	0.930	+0.002
FACTCK.BR	1.00	0.924	0.919	−0.005
WhatsApp.Br	0.05	0.659	0.661	+0.002
WhatsApp.Br	0.10	0.672	0.668	−0.004
WhatsApp.Br	0.20	0.706	0.710	+0.004
WhatsApp.Br	0.50	0.712	0.717	+0.005
WhatsApp.Br	1.00	0.712	0.734	+0.022

mais sementes e decision models calibrados, em vez de refinar o score de seleção.

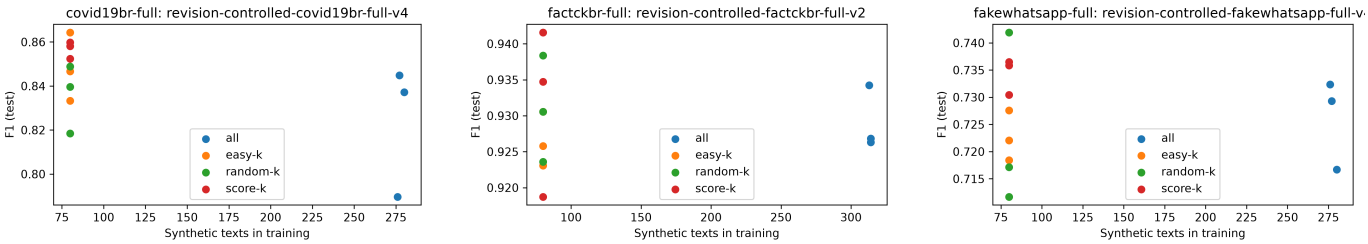


Fig. 1. F1 × número de sintéticos herdados (cenário full, três domínios).

REFERENCES

[1] M. de Souza and C. Zanchettin, "Breaking the Barrier of Hard Samples: A Data-Centric Approach to Synthetic Data for Medical Tasks," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2025.

[2] J. Ye, J. Gao, Q. Li, H. Xu, J. Feng, Z. Wu, T. Yu, and L. Kong, "ZeroGen: Efficient Zero-shot Learning via Dataset Generation," in *Proc. EMNLP*, 2022.

[3] Y. Meng, J. Huang, Y. Zhang, and J. Han, "ProGen: Progressive Zero-shot Dataset Generation via In-context Feedback," in *Findings of EMNLP*, 2022.

[4] J. Gao, R. Pi, Y. Lin, H. Xu, J. Ye, Z. Wu, W. Zhang, X. Liang, Z. Li, and L. Kong, "Self-Guided Noise-Free Data Generation for Efficient Zero-Shot Learning," in *Proc. ICLR*, 2023.

[5] B. Settles, "Active Learning Literature Survey," Univ. of Wisconsin-Madison, Tech. Rep. 1648, 2009.

[6] S. Swayamdipta, R. Schwartz, N. Lourie, Y. Wang, H. Hajishirzi, N. A. Smith, and Y. Choi, "Dataset Cartography: Mapping and Diagnosing Datasets with Training Dynamics," in *Proc. EMNLP*, 2020.

[7] R. Monteiro, R. Santos, T. Pardo, T. de Almeida, E. Ruiz, and O. Vale, "Contributions to the Study of Fake News in Portuguese: New Corpus and Automatic Detection Results," in *Proc. PROPOR*, 2018.

[8] L. Cabral et al., "FakeWhatsApp.Br: NLP and Machine Learning Techniques for Misinformation Detection in Brazilian Portuguese WhatsApp Messages," in *Proc. ICEIS*, 2021.

[9] L. Cabral et al., "COVID19.BR: A Dataset of Misinformation about COVID-19 in Brazilian Portuguese WhatsApp Messages," Zenodo, 2020.

[10] J. G. Moreno and G. Bressan, "FACTCK.BR: A Dataset to Study Fake News," in *Proc. WebMedia*, 2019.

[11] F. Souza, R. Nogueira, and R. Lotufo, "BERTimbau: Pretrained BERT Models for Brazilian Portuguese," in *Proc. BRACIS*, 2020.

[12] I. Shumailov et al., "AI Models Collapse When Trained on Recursively Generated Data," *Nature*, vol. 631, 2024.